

pandas 核心		DataFrame Essentials
读写		
pd.read_csv(p, dtype =, parse_dates=)		CSV(指定 dtype 省内存)
pd.read_parquet(p)		列式,大数据首选
pd.read_excel		read_sql
Excel / 数据库		
df.to_csv(p, index=False)		导出
选取		
df[["a"]]		df[["a","b"]]
单列 / 多列		
df.loc[mask, "a"]		标签 + 条件
df.iloc[0:5, :2]		位置
df.query("a>0 and b= 'x'")		字符串条件,变量用 @
链式 / 修改		
df.assign(c=lambda d: d.a+d.b)		加列(可链式)
df.rename(columns= {"a": "A"})		改名
df.drop(columns= ["a"])		删列
df.sort_values("a", ascending=False)		排序
合并		
pd.concat([a,b], axis=0)		纵 / 横拼接
a.merge(b, on="id", how="left")		SQL 风格 join
df.apply(fn, axis=1)		逐行函数(慢,优先向量化)

可视化	Plotting
matplotlib(底层)	
import matplotlib.pyplot as plt	
fig, ax = plt.subplots(figsize=(8,4))	
ax.plot(x, y, label="A")	
ax.set(title="...", xlabel="t", ylabel="v")	
ax.legend()	
plt.tight_layout(); plt.show()	
seaborn(统计)	
sns.lineplot	/
scatterplot	折线 / 散点
sns.barplot	/
countplot	柱 / 计数柱
sns.boxplot	/
violinplot	箱 / 小提琴
sns.histplot	/
kdeplot	直方 / 核密度
sns.heatmap(corr, annot=True)	相关热力
sns.pairplot(df, hue="cls")	两两散点矩阵
sns.FacetGrid / catplot	分面(按列拆图)
plotly(交互)	
px.line / bar / scatter	Express 一行出图
fig.update_layout(...)	改标题/图例/主题
fig.write_html(p)	导出可分享 HTML
pandas 内置	
df.plot(kind="bar")	快速看一眼
df.hist(bins=30)	所有数值列直方

SQL 速查	SQL Essentials
基础查询	
SELECT col, COUNT(*) AS n	
FROM t	
WHERE dt >= '2026-01-01'	
GROUP BY col	
HAVING n > 10	
ORDER BY n DESC	
LIMIT 100;	
JOIN	
INNER JOIN	交集(默认)
LEFT / RIGHT JOIN	保左 / 右
FULL OUTER JOIN	并集
CROSS JOIN	笛卡儿积
窗口函数	
ROW_NUMBER() OVER (PARTITION BY user_id ORDER BY ts DESC)	AS rn
LAG(x,1) OVER(...) -- 前一行	
LEAD(x,1) OVER(...) -- 后一行	
SUM(x) OVER(ORDER BY ts ROWS BETWEEN 6 PRECEDING AND CURRENT ROW)	
CTE / 子查询	
WITH ranked AS (SELECT *, ROW_NUMBER() OVER(...) rn FROM events)	
SELECT * FROM ranked WHERE rn=1;	
实用	
COALESCE(a, b, 0)	取首个非 NULL
CASE WHEN ... THEN ... END	条件表达式
CAST(x AS INT)	类型转换

统计分析	Statistics
描述统计	
df.describe(include="all")	数值 / 类别概览
s.mean / median / std / var	中心 / 离散
s.skew()	.
s.kurt()	偏度 / 峰度
s.quantile([.25,.5,.75])	四分位
相关	
df.corr(method="pearson")	线性相关
method="spearman"	秩相关(抗异常)
df.cov()	协方差
假设检验(scipy.stats)	
ttest_ind(a, b, equal_var=False)	两独立样本 t 检验
ttest_rel(before, after)	配对 t
mannwhitneyu(a, b)	非参替代
chi2_contingency(table)	卡方独立性
f_oneway(g1, g2, g3)	单因素 ANOVA
shapiro(s)	正态性检验
pearsonr(x, y)	相关 + p 值
回归	
statsmodels.api.OLS(y, X).fit()	线性回归(带统计量)
res.summary()	系数 / R² / p / 置信区间
smf.logit("y~x", df).fit()	逻辑回归(公式)

数据清洗 & 类型	Cleaning & Types
缺失值	
df.isna().sum()	每列缺失计数
df.dropna(subset=["a"])	删带 NA 的行
df.fillna({"a":0, "b":-1})	按列填充
df.ffill()	/
bfill()	前 / 后向填充
df["a"].interpolate()	插值(数值/时间)
去重	
df.duplicated(subset=)	布尔标记重复
df.drop_duplicates(keep="last")	去重
类型	
df.dtypes	df.info()
查看类型	
df.astype({"a": "int32"})	强转类型
df.convert_dtypes()	推断为新可空类型
pd.to_datetime(s, errors="coerce")	日期(失败置 NaT)
pd.to_numeric(s, errors="coerce")	数值化
s.astype("category")	类别型,大幅省内存
字符串 / 异常值	
s.str.strip()	.
.lower()	去空白 / 小写
s.str.contains(r"\d+")	正则匹配
s.str.extract(r"(\d+)")	提取分组

A/B 测试	Experimentation
流程	
› 定 OEC 主指标 + 护栏(留存 / 收入 / 错误率)	
› 事前算 样本量,定 停止规则,锁定再开实验	
› 实验中只看 SRM / 健康度,不偷看主指标	
› 到量后一次性出结论;显著 → 看效应量,不只是 p	
样本量(Power Analysis)	
from statsmodels.stats.power \	
import NormalIndPower, tt_ind_solve_power	
# 给定 effect/alpha/power 求 n	
n = tt_ind_solve_power(effect_size=0.05, alpha=0.05, power=0.8, alternative="two-sided")	
指标对比	
proportions_ztest([x1,x2],[n1,n2])	两组转化率
ttest_ind(a, b)	两组均值(连续)
bootstrap (n=10000)	无分布假设求 CI
CUPED	
分层抽样	降方差,提小流量灵敏度
多重检验	
multipletests(pvals, method="fdr_bh")	BH FDR(推荐)
method="bonferroni"	最严,小指标数
陷阱	
› SRM(样本比例不匹配)= 分坏环了,先排除	
› Peeking(连续偷看)放长假阳,用顺序检验或锁结果	
› 新奇效应 / 冷启动:看周维度趋势,别只看天	
› Simpson 悖论:总体反向 → 分层看子群	

聚合 & 透视	Group / Pivot / Time
groupby	
df.groupby("city").agg(n=("id","count"), rev=("amt","sum"), avg=("amt","mean"),)	
# 多分组 + 多函数	
df.groupby(["city","plan"])["amt"] \	
.agg(["sum","mean","std"])	
# transform: 同形状回填(算占比)	
df["share"] = df["amt"] / \	
df.groupby("city")["amt"].transform("sum")	
透视 / 交叉	
pd.pivot_table(df, index, columns, values, aggfunc)	透视表
pd.crosstab(a, b, normalize="index")	列联表 + 比例
df.melt(id_vars=, value_vars=)	宽表 → 长表
df.pivot(index, columns, values)	长表 → 宽表
时序	
df.set_index("ts").resample("D").sum()	按天聚合
.resample("W") / "M" / "1H"	周 / 月 / 时
s.rolling(7).mean()	7 期滚动均值
s.expanding().sum()	累计
s.shift(1)	.
s.diff()	滞后 / 差分
s.pct_change()	环比涨跌

工具链 & Pro Tips	Tooling & Tips
高性能替代	
polars	Rust + 多核,10x pandas;Lazy API
duckdb	本地 OLAP,可直接查 parquet/csv/df
pyarrow	列式内存格式,跨工具零拷贝
dask / modin	大数据 / 多核 pandas 兼容
DuckDB 一行查 DataFrame	
import duckdb	
duckdb.sql("SELECT city, AVG(amt) " "FROM df GROUP BY 1").df()	
Jupyter 魔法	
%timeit expr	微基准
%time	整 cell 计时
%load_ext autoreload	改代码自动重载
!cmd	.
?obj	跑 shell / 看文档
质量与协作	
› 用 parquet 而不是 csv,省 10x 空间 + 类型保留	
› 向量化 比 apply 快 10–100x; category 省内存 10x	
› 报告:nbconvert · Quarto · Streamlit	