

训练闭环

Data
batch + label
增强/归一化

Forward
y = f(x; θ)
层层计算

Loss
CE / MSE / Dice
衡量错误

Backprop
链式法则
求 ∂θ L

Update
AdamW / SGD
θ ← θ - η∇L

公式与直觉

y=f(x;θ)
L(y,ŷ)
θ←θ−η∇L
Backprop
Jacobian
BatchNorm
LayerNorm
Weight Decay

网络是参数化函数,层层复合
损失衡量预测与真值差距
梯度下降:η 是学习率
链式法则自动求每层梯度
向量函数局部导数矩阵,理解梯度流
按 batch 归一化;小 batch/序列任务谨慎
按特征归一化;Transformer 常用
惩罚大权重,AdamW 解耦更常见

面试一句话 · 反向传播不是算法魔法,是把链式法则高效缓存并复用。

层与模块

Layers

Linear
ReLU/GELU
Sigmoid/Tanh
Conv
Kernel/Stride
Padding
Dilated Conv
Depthwise Conv
Transposed Conv
Pooling
Global AvgPool
Embedding
Attention
Cross-Attn
Positional Enc.
Norm
Dropout
Residual
Init
Softmax

仿射变换 xW+b ,最基础可学习层
非线性;否则多层线性仍是线性
易饱和和梯度小;门控结构仍常见
局部连接 + 权值共享,图像/时序高效
卷积核尺寸/步幅决定感受野与输出大小
控制边界与尺寸;same/valid 常见
空洞卷积扩大感受野,分割/时序常用
逐通道卷积,移动端模型省计算
可学习上采样,生成/分割解码器常见
降采样,扩大感受野,减少计算
把空间维压成通道统计,分类时常用
离散 id → 稠密向量,文本/类别常用
按相关性动态汇聚上下文信息
一个序列查询另一个序列,多模态/扩散常用
补充顺序/空间位置信息
Batch/Layer/RMSNorm 稳定训练
训练随机置零,降低共适应
让层学习增量,解决深层退化
Xavier/He 初始化让信号方差稳定
logits → 概率;数值稳定需减 max

架构族谱

Architectures

MLP
ResNet
DenseNet
EfficientNet
CNN
U-Net
YOLO
Mask R-CNN
RNN/LSTM
Transformer
BERT/GPT
Autoencoder
VAE
GAN
Diffusion
GNN
Multimodal

表格/简单特征;无结构先验
残差网络,深层 CNN 代表
层间密集连接,特征复用强
宽度/深度/分辨率复合缩放
图像、局部模式、平移不变性
编码-解码 + skip,分割/扩散常见
单阶段检测,速度快,工程常见
检测 + 实例分割,两阶段高精度
序列递归建模,长依赖较难
并行序列建模,长序列成本高
Encoder 理解 / Decoder 生成
编码-解码,压缩/去噪/异常检测
潜变量生成模型,重构 + KL 正则
生成器 vs 判别器,训练不稳定但锐利
逐步去噪生成,图像/视频主流
节点/边/图上的消息传递
图文音视频融合,常靠对齐和 cross-attn

优化器

Optimization

SGD
Momentum
Nesterov
Adam
AdamW
RMSProp
Warmup
Cosine
Clip Grad
EMA
Scheduler
Batch Size

简单稳,配 momentum 常泛化好
累计速度,减少震荡,加速谷底前进
先看前方梯度,比普通 momentum 更敏锐
自适应一二阶矩,默认好用
解耦 weight decay,Transformer 常用
按平方梯度缩放,早期 RNN 常用
初期逐步升 LR,防大模型训练崩
学习率平滑衰减,尾部细调
限制梯度范数,防爆炸
参数滑动平均,提升评估稳定性
LR 曲线通常比优化器细节更影响结果
大 batch 需调 LR,小 batch 噪声更强

排错与面试

Debug / Interview

训练不动 · 查 label 是否错位、loss 是否连到参数、optimizer 是否 step
loss NaN · 学习率过大、除零、log(0)、fp16 溢出、梯度爆炸
过拟合 · 训练好验证差,加数据、正则、早停、增强、减模型
欠拟合 · 训练也差;加容量、训久、调学习率、检查特征
梯度消失 · 深层早期层梯度近零;残差/归一化/激活改善
梯度爆炸 · 梯度异常大;clip grad、降 LR、修初始化
数据泄漏 · 验证集信息进训练,线上会崩;按时间/用户分割
类别不平衡 · accuracy 虚高;看 F1/PR-AUC,加权或采样
Batch size · 大 batch 稳定但泛化可能变差;LR 常需随之调
学习率 · 最敏感超参;先做 LR range test 或 warmup
初始化 · Xavier/He 让方差稳定传递
正则化 · dropout、weight decay、data aug、label smoothing
可解释性 · saliency/attention/SHAP 只能辅助,别过度解读
部署指标 · latency、throughput、显存、冷启动、漂移、成本
最小验证 · 小数据上能否 100% overfit 是第一块试金石
shape 先行 · 每层输出形状写清楚,80% bug 是维度/广播问题
数据归一化 · 输入尺度不稳会让优化器像在崎岖地形里乱走
loss 选错 · 多标签用 BCE,多分类用 CE,回归别默认 MSE 到底
验证集波动 · 样本少或 batch 噪声大;看滑动平均和置信区间
增强过强 · train 变难但 label 不再可靠,会拖慢或误导训练
预训练 · 数据少时先迁移学习,最后几层微调起步
冻结层 · 先冻 backbone 训 head,再逐步解冻
蒸馏 · 学 logits/hidden/attention,常比硬标签更平滑
量化校准 · 需要代表性数据,否则少数层误差会放大
线上漂移 · 输入分布、标签延迟、用户反馈都会变

任务与损失

Tasks

Classification
Regression
Imbalance
Segmentation
Detection
Generation
Contrastive
Language Model
Metric Learning
RL
Multi-task

交叉熵;多标签用 BCE
MSE/MAE/Huber;注意目标缩放
class weight/focal loss/重采样
像素级分类;Dice/IoU 常用
框回归 + 分类 + NMS
自回归/扩散/GAN,评价更复杂
拉近正样本,推远负样本
next token 交叉熵,困惑度评估
学相似度空间,检索/人脸常用
奖励驱动策略学习,信号稀疏更难
共享骨干多头输出,需平衡 loss 权重

工程化

Production

Dataset
Experiment
Seed
Checkpoint
AMP
DDP/FSDP
Pipeline Parallel
Tensor Parallel
Quantization
QAT / PTQ
Distillation
LoRA / Adapter
Pruning
ONNX/TensorRT
Serving
Monitoring

版本化原始数据、切分、清洗规则
记录 config、seed、代码版本、指标
固定随机性;重要结论跑多 seed
保存权重/优化器/step,支持恢复
混合精度训练,注意溢出和 loss scale
多卡数据并行/参数分片
模型按层切到多卡,需处理气泡
矩阵乘切分到多卡,大模型常用
INT8/INT4 降显存提速,精度需回归测
量化感知训练 / 训练后量化
小模型学大模型输出,降成本
参数高效微调,只训少量增量层
剪掉低贡献权重/通道,需微调恢复
跨框架/高性能推理部署
batching、并发、冷启动、降级策略
漂移、延迟、错误、反馈闭环

Deep Learning · Goodfellow/Bengio/Courville | Stanford CS231n / CS224n | PyTorch docs | 由 Claude 整理 · 2026-05