

Ollama	易上手首选
基础命令	
ollama pull llama3.3	下载模型
ollama run <model>	交互对话
ollama list	本地模型清单
ollama ps	运行中的模型
ollama rm <model>	删除模型
ollama show <model>	查看 Modelfile/参数
API 兼容	
:11434/api/chat	原生 API
:11434/v1	OpenAI 兼容端点
OLLAMA_HOST=0.0.0.0	局域网共享
Modelfile 自定义	
FROM llama3.3	
SYSTEM "你是简洁助手"	
PARAMETER temperature 0.3	
PARAMETER num_ctx 8192	
ollama create mybot -f Modelfile	

llama.cpp	C++ 引擎
构建	
cmake -B build -DGGML_METAL=ON	Metal/OSX GPU
cmake -B build -DGGML_CUDA=ON	CUDA/显卡 GPU
cmake -B build -DGGML_VULKAN=ON	Vulkan/显卡 GPU
运行	
llama-cli -m model.gguf	命令行推理
llama-server -m m.gguf	OpenAI 兼容 HTTP
-ngl 99	offload 全部层到 GPU
-c 8192	上下文长度
-t 8	CPU 线程数
--temp 0.7 --top-p 0.95	采样参数
量化工具	
llama-quantize in.gguf out.q4_K_M	压缩模型为 Q4_K_M
convert_hf_to_gguf.py	HuggingFace → GGUF
生态	
是 Ollama、LM Studio、Jan、GPT4All 底层;HF GGUF 生态最大	

vLLM	生产级高吞吐
核心特性	
PagedAttention	显存高效
Continuous batching	动态分批
Speculative decoding	投机解码
Prefix caching	system 复用
启动	
llm serve Qwen/Qwen2.5-32B-Instruct \	
--tensor-parallel-size 2 \	
--max-model-len 32768 \	
--quantization awq \	
--gpu-memory-utilization 0.9	
客户端	
OpenAI(base_url=":8000/)	完全兼容 SDK
/v1/chat/completions	chat 端点
/v1/completions	补全端点
何时用	
多用户并发 / SaaS 后端 / 评测推理;开发期不必要	

MLX / LM Studio / 其他	Apple & GUI
MLX(Apple Silicon 原生)	
pip install mlx-lm	安装
mlx_lm.generate --model Llama-3.3-70B-Instruct	本地推理
mlx_lm.server --model XOpenAI	兼容服务
mlx_lm.lora	本地 LoRA 微调
M2/M3 统一内存吃满,比 llama.cpp 略快	
LM Studio	
GUI 桌面端,内嵌 llama.cpp;模型浏览/下载/聊天/本地 API 一体;新手友好	
其他	
Jan	开源跨平台 GUI
GPT4All	桌面 + Python SDK
text-generation-webui	老牌 WebUI(oobabooga)
LocalAI	自托管多模型网关
Open WebUI	Ollama 配套 Web 前端

模型推荐 2026	Models
通用对话	
Llama 3.3 70B	Meta · 通用基线
Qwen3 / Qwen2.5-72B	阿里 · 中文/推理强
DeepSeek-V3 / R1	推理 MoE,本地需 4x 24G
Mistral Large / Nemo	欧洲法语友好
Gemma 3	Google 开源
Phi-4 14B	微软 · 小而精
编程优化	
Qwen2.5-Coder-32B	代码 SOTA(开源)
DeepSeek-Coder-V2	MoE 代码模型
Codestral	Mistral 代码
小模型	
Llama 3.2 1B/3B	手机/边缘
Qwen2.5 0.5B/1.5B/3B	超轻量级
多模态	
Llama 3.2 Vision	11B/90B 看图
Qwen2.5-VL	视觉 + 中文

量化格式	Quantization
主流格式	
GGUF	llama.cpp/Ollama,最通用
AWQ	activation-aware,推理快
GPTQ	较老,逐渐被 AWQ 取代
EXL2 / EXL3	exllamav2,N 卡最快
MLX-quant	Apple 专用,4/8 bit
bitsandbytes nf4	transformers 内置
GGUF 档位选择	
Q2_K	极限压缩,质量损失大
Q4_K_M	推荐起点,平衡
Q5_K_M	质量更好,慢一点
Q6_K	接近 FP16
Q8_0	几乎无损
速记	
K = K-quants 新型;_M / _S / _L 不同分组;Q4_K_M 是质量/大小最佳折中	

硬件参考	VRAM Sizing
估算公式	
VRAM ≈ 参数量 × 量化字节(Q4≈0.5B,Q8≈1B,FP16≈2B)+ KV cache(随 context 增长)	
常见组合(Q4_K_M)	
7B Q4	~5 GB · 8G 卡轻松
13B Q4	~9 GB · 12G 起步
32B Q4	~20 GB · 24G 单卡
70B Q4	~40 GB · 48G/双 24G
DeepSeek-V3 671B	MoE,~400G,本地极难
显卡梯队	
RTX 3090/4090 24G	家用首选
RTX 5090 32G	新一代旗舰
A100 40/80G	工作站/云
H100 / H200	生产级
Apple Silicon	
M2/M3 Max 64-128G	可跑 70B Q4
M3 Ultra 192-512G	405B / MoE 都行

微调 & Pro Tips	Fine-tuning & Tips
微调工具	
unsloth	2x 速度,5x 省 VRAM
axolotl	配置驱动,生态广
Llama-Factory	中文社区流行
mlx_lm.lora	Apple 原生
torch tune	PyTorch 官方
方法	
LoRA / QLoRA	参数高效,4-bit base
SFT / DPO / ORPO	指令 / 偏好 / 单步偏好
Pro Tips	
先用 Ollama 跑通,再决定要不要换 vLLM/llama.cpp 直跑	
Apple 上 MLX 比 llama.cpp 稍快,内存吃满	
多人并发服务必用 vLLM,单人对话 Ollama 够了	
量化先选 Q4_K_M,质量不够再 Q5/Q6	
context 越长 KV cache 越吃 VRAM,留出 20-30% 空间	
HF 找模型加 -GGUF / -AWQ 关键字搜量化版	
本地接 IDE:Cursor / Cline / Continue 都支持 Ollama base_url	