

机器学习闭环

Problem → Model → Decision

Problem

目标/成本/约束
定义成功指标

Data

采样/标签/切分
先防泄漏

Features

清洗/编码/聚合
训练线上一致

Model

baseline → GBDT
fit / predict

Decision

阈值/A-B/监控
反馈闭环

任务类型

Tasks

Classification

二分类/多分类/多标签,输出类别概率

Calibration

分类分数能否当概率用,业务决策关键

Regression

预测连续值,关注误差分布和异常值

Ranking

学习排序,搜索/推荐/广告核心

Recommendation

召回→粗排→精排→重排,多目标权衡

Clustering

无标签分群,解释性常比指标更重要

Anomaly

异常检测,正负样本极不平衡

Forecasting

时间序列预测,切分必须尊重时间

Uplift

预测干预增量效果,营销/策略常用

Bandit

探索/利用,推荐和实验分流常见

Causal

估计干预效果,相关不等于因果

Survival

时间到事件建模,流失/故障风险

数据与特征

Data / Features

Split

train/val/test;时间任务按时间切

Group Split

同用户/设备/商品不能跨集合泄漏

Leakage

未来信息、目标代理、重复用户泄漏

Missing

缺失本身可能是信号;先查机制

Imputation

均值/中位/模型填补;保留缺失指示

Outlier

错误/极端真实值分开处理

Winsorize

截尾处理极端值,比删除更稳

Scaling

线性/KNN/SVM 重要;树模型通常不敏感

One-hot

低基数类别;高基数考虑 target/hash encoding

Hashing

高基数类别压缩,有碰撞但线上简单

Target Encoding

强但易泄漏,必须 K-fold/平滑

Window Feature

过去 7/30 天统计,注意时间穿越

Feature Store

训练/线上一致,避免口径漂移

模型家族

Models

Linear/Logistic

强 baseline,快、可解释、抗小数据

Ridge/Lasso

L2 稳定系数,L1 促稀疏选特征

Naive Bayes

文本分类简单有效,特征独立假设强

KNN

懒学习,特征尺度/维度灾难敏感

SVM

间隔最大化;核方法强但大数据慢

Decision Tree

可解释但高方差,易过拟合

Random Forest

bagging 降方差,稳健少调参

GBDT

XGBoost/LightGBM/CatBoost 表格王者

CatBoost

类别特征友好,ordered target encoding

IsolationForest

异常检测,随机切分隔离异常点

KMeans/DBSCAN

中心聚类/密度聚类,假设不同

Neural Net

大数据/非结构数据强,调参与部署成本高

Stacking

多模型输出再训练二层模型,易泄漏需 OOF

Blending

验证集上融合,简单但会消耗验证数据

Rule + ML

规则兜底边界,模型处理灰区

AutoML

快速找 baseline,最终仍需理解数据

指标选择

Metrics

Accuracy

类别均衡可用;不平衡时会骗你

Precision

预测为正里有多少真正;误报成本高看它

Recall

真正例找回多少;漏报成本高看它

F1

Precision/Recall 调和平均,折中指标

ROC-AUC

阈值无关排序能力;极不平衡看 PR-AUC

LogLoss

概率质量好坏;惩罚过度自信错误

RMSE/MAE

回归误差;RMSE 更惩罚大错

NDCG/MAP

排序/推荐/搜索常用

HitRate@K

推荐前 K 是否命中,召回阶段常用

Recall@K

检索/推荐找回目标比例

Lift

相对随机/基线提升倍数,营销常用

Brier Score

概率校准误差,越低越好

KS

风控评分卡查看正负样本分离度

验证与调参

Validation

K-Fold

小数据稳估计;同用户样本需 group fold

Stratified

分类保持各折类别比例

Time Split

预测未来必须用过去训练、未来验证

Purged Split

时间窗口重叠时清除邻近泄漏

Nested CV

外层评估,内层调参,防乐观偏差

Grid Search

小空间可用;维度高浪费

Random Search

通常比网格更划算

Bayes Opt

昂贵训练时用,逐步试更可能好的点

Learning Curve

看数据量增加能否继续收益

Validation Curve

看单个超参对 train/val 的影响

Early Stop

验证集不涨即停,GBDT/NN 常用

Seed

固定随机性;重要结论跑多 seed

统计基础

Stats

p-value

原假设下更极端结果概率,不是真伪概率

CI

区间估计不确定性;比单点指标诚实

Power

真有效应被检出的概率,样本量设计关键

Effect Size

效果大小;显著不等于有业务价值

Bayes

先验×似然→后验,适合小样本不确定性

Regularization

用约束换泛化,防止记住噪声

Multiple Test

多次试验会抬高假阳,需校正或预注册

Confounder

同时影响因果两端的第三变量

RCT

随机对照是因果识别金标准

DID / IV

双重差分/工具变量,准实验常用

Bootstrap

重采样估不确定性,少分布假设

Permutation

打乱标签检验指标是否可能偶然

面试题卡

Interview Checklist

先问目标

· 优化点击率、召回率、收入、风险、成本,答案会完全不同

Baseline

· 先用规则/均值/逻辑回归/树模型,别直接上复杂模型

切分方式

· 随机切分不一定对;用户、时间、地域都可能泄漏

类别不平衡

· 指标换 PR-AUC/F1/recall@precision,采样或 class weight

过拟合

· train 高 val 低;正则、早停、降复杂、更多数据

欠拟合

· train/val 都差;加特征、模型容量、非线性、调学习率

Bias-Variance

· 高偏差欠拟合,高方差过拟合;学习曲线能诊断

阈值选择

· 根据 FP/FN 成本、容量约束、校准曲线决定

校准

· 业务用概率下注时要看 reliability curve/Brier score

解释性

· 线性系数、树重要性、Permutation、SHAP 各有陷阱

A/B 实验

· 离线好不等于线上好;看护栏指标和统计功效

数据漂移

· 监控输入分布、预测分布、标签延迟后的真实表现

线上一致

· 特征计算、时区、窗口、缺失填充必须训练/线上同源

冷启动

· 新用户/新物品要规则、内容特征或探索策略兜底

业务落地

· 模型只是决策系统一部分,还要解释、回滚、审计

样本定义

· 一行代表什么实体/时间点? 标签窗口和特征窗口必须分开

负样本

· 未点击不一定是喜欢,可能只是没曝光或位置差

训练-服务偏差

· 离线特征和线上实时特征口径差会直接毁模型

延迟标签

· 退款、流失、违约等标签晚到,评估要留观察窗口

阈值漂移

· 分数分布变了,固定阈值会让业务量忽上忽下

分群评估

· 总体指标好也可能伤新用户/小商家/长尾类别

特征重要性

· GBDT gain 有偏;Permutation/SHAP 也受相关特征影响

线上实验

· 先小流量灰度,监控护栏指标,避免只看主指标

反馈闭环

· 模型改变曝光,曝光又改变训练数据,推荐尤其明显

可回滚

· 模型文件、特征代码、阈值、依赖数据都要版本化