

核心流程	Pipeline
索引侧 (Offline / Index)	
load	读源:PDF/HTML/DB/API
chunk	切片成可检索单元
embed	向量化(可加 metadata)
store	入向量库 + 倒排索引
查询侧 (Online / Query)	
retrieve	向量+关键词召回 top-k
rerank	交叉编码精排(可选)
prompt	拼模板 + context
generate	LLM 生成 + cite
关键分界	
Offline	走批处理,贵的 embedding 一次算完;Online 路径要短,延迟 < 1s
索引慢没事,查询慢用户跑	

切分策略	Chunking
常见切法	
fixed-size	固定字符/token,简单但暴力
Recursive	按 \n\n→\n→. 层级递归
Markdown	按 # / ## 标题切,保结构
Sentence	按句号 / NLTK / spaCy
Semantic	embedding 距离突变处切
Code-aware	按函数 / class 切代码
Parent-Child	
小 chunk 用于检索(更精准),大 chunk(父块)送 LLM 当上下文	
参数经验	
chunk_size	200—1000 token,常见 512
chunk_overlap	10—20%,防语义截断
separator	优先按结构切,而非长度

Embedding 模型	Embeddings
闭源 (API)	
text-embedding-3-large	OpenAI · 3072d · 强
text-embedding-3-small	OpenAI · 1536d · 便宜
voyage-3	Voyage · 检索 SOTA
embed-v3	Cohere · 多语种
jina-embeddings-v3	Jina · 长文支持
开源 (自托管)	
BGE-M3	多语+稀疏/密集/多向量
GTE-Qwen2-7B	阿里 · MTEB 顶部
NV-Embed-v2	NVIDIA · 强基座
E5 / mxbai-large	通用轻量
选型看	
维度(影响存储/速度)·最大 token·价格·语种;先看 MTEB Leaderboard	

向量库	Vector Stores
推荐起手	
pgvector Chroma Qdrant	
pgvector 已有 PG 直接加;Chroma 本地嵌入式,prototype 神器;Qdrant Rust 写,生产高性能	
托管 / 云	
Pinecone Weaviate Cloud Turbopuffer	
开源大头	
Milvus Weaviate LanceDB FAISS	
混合检索 (BM25 + 向量)	
Elasticsearch OpenSearch Vespa	
看四点	
filter 性能 · HNSW/IVF 参数 · 多租户 · 更新成本	

检索策略	Retrieval
Dense (向量)	
cosine	余弦相似度,常用
dot product	点积,需 normalize
L2 / Euclidean	欧氏距离
Sparse (关键词)	
BM25	经典词频检索,精确 match 强
SPLADE	学习型稀疏,稀疏向量
Hybrid	
RRF	Reciprocal Rank Fusion
weighted	$\alpha \cdot \text{dense} + (1-\alpha) \cdot \text{sparse}$
后处理	
MMR	最大边际,去重多样化
filter	metadata 硬过滤(时间/源)
MultiQuery	LLM 改写多版本查询并集

高级技巧	Advanced
查询变换	
HyDE	让 LLM 先写假设答案再检索
Query Rewrite	改写口语成检索友好
Query Expansion	扩同义词 / 多版本
Step-Back	先抽更抽象的问题
索引结构	
Parent-Child	小检索 · 大上下文
Contextual Retr.	Anthropic · chunk 前置摘要
Hierarchical	树状摘要(RAPTOR)
GraphRAG	实体图 + 社区摘要
深度检索	
CoLBERT	late interaction · 多向量
Agentic RAG	LLM 自主多轮检索

Rerank & 评估	Rerank & Eval
Rerank 模型 (cross-encoder)	
Cohere Rerank-3	API · 多语种 · 业界标杆
Voyage Rerank-2	API · 高精度
Jina Reranker v2	API + 开源版
BGE Reranker	开源自托管
Ragas 四指标	
faithfulness	答案是否忠于 context
context precision	召回里有用比例
context recall	真值是否被召回
answer relevancy	答案是否切题
其它框架	
TruLens · ARES · DeepEval · LangSmith eval;先建 golden dataset (50—200 条人标),回归驱动	

Pro Tips	Pro Tips
切分质量 > 模型选择:同一份数据,好切分能让 recall +20%	
加 metadata filter(时间/来源/权限/语种),用硬过滤替代部分语义	
检索 top-50 → rerank 收到 5—8,几乎免费拉精度	
eval 驱动迭代:任何改动都要看 Ragas 四指标变化	
别只测 happy path,要造 对抗集(过期/无答案/多跳)	
embedding 走 offline batch,合并请求省 5—10× API	
大文档用 Contextual Retrieval(Anthropic)减 35% miss	
用户提问短/口语 → 先 HyDE 或 query rewrite 再检索	
Hybrid (BM25 + dense) 几乎总比纯向量好,先上 RRF	
多语种数据 → 选 BGE-M3 / Cohere v3,别用单语模型	
chunk_size 别死磕 512,按文档结构(段/标题)切更稳	
幻觉防线:引用 + "context 没说就拒答" 的指令	
查询日志接 反馈循环,差的 case 定期回炉训 reranker	
权限隔离:filter at query time,别在 prompt 里写"忽略 X"	
真小项目 BM25 + LLM 已够用,别一上来就上向量库	