



Block 组件	Inside Layer
LayerNorm	稳定激活分布;LLM 多用 RMSNorm 变体
RMSNorm	只按均方根归一化,省均值计算,LLM 常见
Residual	$x + \text{sublayer}(x)$,保持信息高速路
Residual Stream	主干信息通道,各层不断读写增量
MLP / FFN	逐 token 前馈网络,通常扩到 4d
GELU / SiLU	激活函数,现代 LLM 常用 SwiGLU
SwiGLU	门控 MLP,效果好但参数/计算更多
MHA	Multi-Head Attention,每头独立 Q/K/V
MQA / GQA	共享或分组 K/V,显著省 KV cache
Causal Mask	上三角遮蔽未来 token,生成任务必需
FlashAttention	分块重算 softmax,少读写显存提速
Dropout	训练正则;大模型预训练中用法因架构而异
Pre-LN	$x + \text{Attn}(\text{LN}(x))$,深层训练更稳
Weight Tying	输入 embedding 与输出 head 共享权重
RoPE	旋转位置编码,长上下文模型常见

训练与推理	Train / Inference
Objective	Decoder LLM: next-token prediction
Teacher Forcing	训练时一次喂完整真值序列,并行算 loss
Cross Entropy	预测分布与目标 token 的负对数似然
Optimizer	AdamW + warmup + cosine/linear decay 常见
Sequence Packing	短样本拼接减少 padding 浪费
Grad Accum.	多步累积梯度模拟大 batch
Checkpointing	反向重算中间激活,省显存换时间
Mixed Precision	bf16/fp16 降显存提吞吐,注意 loss scale
Prefill	一次处理输入 prompt,通常算力密集
Decode	逐 token 生成,常受显存带宽限制
KV Cache	生成阶段缓存历史 K/V,显存随上下文线性涨
PagedAttention	分页管理 KV cache,服务端开发更稳
Sampling	temperature/top-p/top-k 控随机性与多样性
Beam Search	保留多条候选;开放生成常不如采样自然
Spec Decode	小模型草稿 + 大模型验收,降低延迟

定位错误	Debug Checklist
shape	先查 [B,T,H,D] 转置/reshape
mask	mask 方向错会偷看未来或全被遮
nan	学习率过大、fp16 溢出、softmax 输入异常
loss flat	数据/标签错位,optimizer 未更新,mask 错
slow	attention $O(n^2)$,batch 太碎,KV cache 未用
overfit	数据少、训练太久、验证泄漏或增强不足
eval gap	训练 prompt 与线上 prompt 不一致
deploy	吞吐看 batching,延迟看首 token/解码速度
oom	降 batch/context,开 checkpoint,量化或张量并行
repeat	温度过低/惩罚不足/上下文循环触发
lost in middle	长上下文中段信息弱,用重排/摘要/分块
bad tool	工具 schema 不清、参数未校验、观测未回填

常见变体	Variants
BERT	Encoder-only,理解/分类/检索 rerank
GPT	Decoder-only,自回归文本生成
T5	Encoder-Decoder,文本到文本
BART	去噪自编码 Seq2Seq,摘要/生成常见
ViT	图像切 patch 当 token 做视觉任务
CLIP	图文对比学习,共享语义空间
Diffusion U-Net	常用 cross-attention 融合文本条件
GQA / MQA	减少 K/V 头数,降低 KV cache 成本
MoE	路由到少数专家,提升参数规模/成本比
Router	MoE 决定 token 进哪个专家,需负载均衡
Linear Attn.	用近似降低长序列二次成本
State Space	Mamba 等替代序列建模路线,长序列高效
RAG + LLM	模型负责推理表达,外部检索补事实

面试速记	Questions
为什么缩放? QK 点积维度大时方差变大,softmax 饱和,所以除以 $\sqrt{dk}$	
为什么多头? 不同头在不同子空间看语法、位置、实体、长程依赖	
Attention 复杂度? 序列长 n 时注意力矩阵 $n \times n$,时间/显存约 $O(n^2)$	
Residual 作用? 保梯度、让层学增量变换,深层更稳	
LayerNorm 位置? Pre-LN 训练深模型更稳; Post-LN 是原论文结构	
Encoder vs Decoder? Encoder 双向理解; Decoder 因果生成; Seq2Seq 适合翻译/摘要	
位置怎么进模型? 绝对位置、相对位置、RoPE/ALiBi 等,解决顺序信息	
KV Cache 是什么? 推理时缓存历史 K/V,新 token 只算新增 Q,避免重复算前文	
训练 vs 推理? 训练可并行看全序列; 推理逐 token 生成,常被 memory bandwidth 限制	
长上下文难点? 注意力成本、位置外推、检索噪声、上下文遗忘	
幻觉原因? 语言建模目标不是事实数据库; 缓解靠 RAG、工具、校验、引用	
MoE 为什么省算? 每个 token 只激活少数专家,参数多但计算稀疏	
Fine-tune 风险? 过拟合、灾难遗忘、格式学偏、安全能力退化	
评估看什么? 任务准确率、鲁棒性、延迟、成本、可解释错误样本	
Pretrain vs SFT? 前者学语言/知识分布,后者学指令格式与任务行为	
RLHF/DPO? 用偏好数据优化回答风格和安全边界,不是补事实	
LoRA 为什么省? 冻结原权重,只训练低秩增量矩阵	
量化影响? 降显存和带宽,但可能伤长尾能力/数学/工具调用	
为什么会重复? 解码分布塌缩、上下文循环、温度/惩罚参数不当	
RAG 何时优于长上下文? 文档多、更新快、需引用、成本敏感时	
函数调用本质? 模型生成结构化参数,外部程序执行并回传观察	
训练数据污染? benchmark 混入训练集会导致评估虚高	
Scaling law? 数据/参数/算力按幂律改善,瓶颈转移但不消失	
最小实现? embedding + causal self-attn + MLP + CE loss + AdamW	